Komputerowe systemy rozpoznawania
2024/2025
Projekt 1. Klasyfikacja dokumentów tekstowych

Mateusz Kosowski 251558
Nikodem Nowak 251598
dr inż. Marcin Kacprowicz

22 marca 2026

Opis projektu ma formę artykułu naukowego lub raportu z zadania badawczego (doświadczalnego/obliczeniowego0 (wg indywidualnych potrzeb związanych np. z pracą inżynierską/naukową/zawodową). Kolejne sekcje muszą być numerowane i zatytułowane. Wzory są numerowane, tablice są numerowane i podpisane nad tablicą, rysunki są numerowane i podpisane pod rysunkiem. Podpis rysunku i tabeli musi być wyczerpujący (nie ogólnikowy), aby czytelnik nie musiał sięgać do tekstu, aby go zrozumieć.

Limit stron sprawozdania: 20. Nie zmieniać parametrów tekstu (czcionki, marginesów, interlinii, itp.). Istotne dla sprawozdania rysunki, tabele, informacje, kody itp. można umieścić w załącznikach, które nie wliczają się do limitu stron.

Wybrane sekcje (rozdziały sprawozdania) są uzupełniane wg wymagań w opisie Projektu 1. i Harmonogramie Zajęć na WIKAMP KSR jako efekty zadań w poszczególnych tygodniach.

1 Cel projektu

Badania będą prowadzone na gotowym zbiorze tekstów Reuters-21578 [1]. W celu przeprowadzenia obserwacji oraz wyciągnięcia wniosków zostanie napisana aplikacja. Jej zadaniem będzie ekstrakcja konkretnych cech tekstu, zamiana ich na wektory a następnie klasyfikacja w kategorii places, z możliwymi etykietami: west-germany, usa, france, uk, canada albo japan.

2 Klasyfikacja nadzorowana metodą k-NN. Ekstrakcja cech, wektory cech

2.1 Zasada działania metody k-NN

Algorytm k-NN (k najbliższych sąsiadów) [2] działa tak, że dla nowego, nieznanego dokumentu:

1. Szuka w bazie k tekstów najbardziej podobnych (najmniejsza odległość między wektorami cech).
2. Sprawdza, do jakich kategorii należą znalezieni sąsiedzi.
3. Przypisuje dokumentowi klasę najczęściej występującą wśród sąsiadów (głosowanie). W przypadku remisu stosuje odpowiednią metodę rozstrzygania.

2.2 Parametry wejściowe

- Wartość k (liczba sąsiadów).
- Proporcje podziału tekstów na zbiór uczący i testowy (np. 60/40).
- Wybrane cechy oraz metryka odległości (np. euklidesowa).

2.3 Wyniki i rezultaty

Program dla każdego tekstu testowego zwraca przewidywaną etykietę (np. `usa`). Na podstawie porównania tych przewidywań z rzeczywistymi kategoriami, program oblicza ostateczne wyniki w postaci czterech miar jakości:

- **Accuracy** (dokładność) – liczona dla całego zbioru dokumentów,
- **Precision** (precyzja) – liczona dla całego zbioru oraz oddzielnie dla każdej z 6 klas,
- **Recall** (czułość) – również dla całego zbioru i wybranych klas,
- **F1** – średnia harmoniczna miar Precision i Recall.

Dzięki tym parametrom można obiektywnie ocenić, jak dobrze model radzi sobie z przypisywaniem tekstów do odpowiednich państw.

2.4 Wyodrębnione cechy (wektory cech)

Dla każdego analizowanego dokumentu wyodrębniono wektor 10 cech (2 tekstowe i 8 liczbowych). Aby ułatwić zapis matematyczny, przyjęto następujące oznaczenia dla pojedynczego dokumentu:

- W – zbiór wszystkich słów w dokumencie, a $n = |W|$ to ich całkowita liczba,
- Z – zbiór wszystkich zdań, a $m = |Z|$ to ich całkowita liczba,
- C – zbiór wszystkich znaków w tekście, a $L_c = |C|$ to całkowita liczba znaków,
- $|x|$ – operator oznaczający długość elementu x (np. liczbę liter w słowie).

Poniżej przedstawiono definicje poszczególnych cech wektora:

1. **Najczęściej występujące słowo** (Most Frequent Word) – wartość tekstowa. Niech W' będzie zbiorem słów po usunięciu tzw. stop-words (spójników, przyimków). Funkcja szuka słowa w, które maksymalizuje liczbę swoich wystąpień $\text{count}(w)$:

$$c_1 = \max_{w \in W'} (\text{count}(w)) \tag{1}$$

   Przykład: `trade`.

2. **Najdłuższe słowo** (Longest Word) – wartość tekstowa. Słowo $w \in W$, dla którego liczba liter $|w|$ jest największa:

$$c_2 = \max_{w \in W} (|w|) \tag{2}$$

   Przykład: `internationalization`.

3. **Średnia długość słowa** (Average Word Length) – wartość liczbowa. Suma długości wszystkich słów podzielona przez ich liczbę:

$$c_3 = \frac{1}{n} \sum_{i=1}^{n} |w_i| \tag{3}$$

   Przykład: 5,43.

4. **Bogactwo słownictwa** (Vocabulary Richness) – wartość liczbowa. Stosunek liczby unikalnych słów do wszystkich słów w dokumencie. Niech $U \subseteq W$ będzie zbiorem słów unikalnych:

$$c_4 = \frac{|U|}{n} \tag{4}$$

   Przykład: 0,65.

5. **Średnia długość zdania** (Average Sentence Length) – wartość liczbowa. Średnia liczba słów przypadająca na jedno zdanie:

$$c_5 = \frac{n}{m} \tag{5}$$

   Przykład: 15,2.

6. **Stosunek wielkich liter** (Uppercase Letter Ratio) – wartość liczbowa. Odsetek znaków, które są wielkimi literami. Jeśli C_{upper} to zbiór wielkich liter w tekście:

$$c_6 = \frac{|C_{\text{upper}}|}{L_c} \tag{6}$$

Przykład: 0,04.

7. **Zagęszczenie znaków finansowych** (Financial/Numerical Sign Density) – wartość liczbowa. Odsetek znaków specjalnych związanych z finansami (np. \$, %, £). Jeśli C_{fin} to zbiór takich znaków w tekście:

$$c_7 = \frac{|C_{\text{fin}}|}{L_c} \tag{7}$$

Przykład: 0,012.

8. **Indeks czytelności Flescha** (Flesch Reading Ease Index) – wartość liczbowa. Wzór oceniający trudność tekstu w jęz. angielskim, gdzie L_{sylab} to całkowita liczba sylab w tekście:

$$c_8 = 206{,}835 - 1{,}015 \cdot \left(\frac{n}{m}\right) - 84{,}6 \cdot \left(\frac{L_{\text{sylab}}}{n}\right) \tag{8}$$

Przykład: 60,5.

9. **Stosunek samogłosek do spółgłosek** (Vowel to Consonant Ratio) – wartość liczbowa. Niech V to liczba samogłosek, a C_{cons} to liczba spółgłosek:

$$c_9 = \frac{V}{C_{\text{cons}}} \tag{9}$$

Przykład: 0,73.

10. **Suma wartości liczbowych** (Sum of All Numerical Values) – wartość liczbowa. Suma matematyczna wszystkich liczb wyciągniętych z treści. Niech Num będzie zbiorem wszystkich wartości liczbowych:

$$c_{10} = \sum_{x \in Num} x \tag{10}$$

Przykład: 105,5.

2.5 Przykład wektora cech

Zgodnie z opisanymi wyżej wzorami, wyekstrahowany wektor v może przyjąć następującaci postać:

$$v = [\texttt{trade}, \texttt{internationalization}, 5.43, 0.65, 15.2, 0.04, 0.012, 60.5, 0.73, 105.5]$$

3 Miary jakości klasyfikacji

W procesie oceny jakości działania klasyfikatora k-NN wykorzystano cztery standardowe miary [3]. Pozwalają one na obiektywną ocenę zdolności modelu do poprawnego przypisywania etykiet dokumentom tekstowym.

Przyjęto następujące oznaczenia dla danej klasy k:

- TP_k (True Positives) – liczba dokumentów z klasy k, które zostały poprawnie zaklasyfikowane do klasy k,
- FP_k (False Positives) – liczba dokumentów spoza klasy k, które zostały błędnie zaklasyfikowane do klasy k,
- FN_k (False Negatives) – liczba dokumentów z klasy k, które zostały błędnie zaklasyfikowane do innej klasy,
- N – całkowita liczba dokumentów w zbiorze testowym.

3.1 Accuracy (Dokładność)

Accuracy określa ogólną skuteczność klasyfikatora jako stosunek liczby poprawnych decyzji do wszystkich podjętych decyzji:

$$Accuracy = \frac{\sum_k TP_k}{N} \tag{11}$$

Miara przyjmuje wartości z zakresu $[0, 1]$, gdzie 1 oznacza bezbłędną klasyfikację. Przykład: $Accuracy = 0{,}85$ (85% poprawnych trafień).

3.2 Precision (Precyzja)

Precyzja dla danej klasy k określa, jaka część dokumentów zaklasyfikowanych do tej klasy faktycznie do niej należy:

$$Precision_k = \frac{TP_k}{TP_k + FP_k} \tag{12}$$

Wysoka precyzja oznacza małą liczbę błędów typu False Positive. Przykład: $Precision_{\texttt{usa}} = 0{,}92$.

3.3 Recall (Pełność/Czułość)

Pełność dla danej klasy k określa, jaką część dokumentów z danej klasy udało się poprawnie wykryć:

$$Recall_k = \frac{TP_k}{TP_k + FN_k} \tag{13}$$

Wysoka pełność oznacza małą liczbę błędów typu False Negative. Przykład: $Recall_{\texttt{usa}} = 0{,}88$.

3.4 Miara F1

Miara F1 jest średnią harmoniczną precyzji i pełności. Pozwala na ocenę balansu między tymi dwiema miarami:

$$F1_k = 2 \cdot \frac{Precision_k \cdot Recall_k}{Precision_k + Recall_k} \tag{14}$$

Jest szczególnie użyteczna w przypadku zbiorów o nierównomiernym rozkładzie klas. Przykład: $F1_{\texttt{usa}} = 0{,}90$.

Dla całego zbioru (wyniki ogólne) stosowana jest średnia arytmetyczna miar cząstkowych dla wszystkich klas (tzw. średnia makro).

4 Metryki i miary podobieństwa tekstów w klasyfikacji

Wzory, znaczenia i opisy symboli zastosowanych metryk z przykładami. Wzory, opisy i znaczenia miar podobieństwa tekstów zastosowanych w obliczaniu metryk dla wektorów cech z przykładami dla każdej miary [**?**]. Oznaczenia jednolite w obrębie całego sprawozdania. **Podaj metryki i miary podobieństwa nie z literatury (te wystarczy zacytować linkiem), ale konkretne ich postaci stosowane w zadaniu. Jakie zakresy wartości przyjmują te miary i metryki, co oznaczają ich wartości? Podaj przykładowe wartości dla przykładowych wektorów cech**.
Sekcja uzupełniona jako efekt zadania Tydzień 04 wg Harmonogramu Zajęć na WIKAMP KSR.

5 Wyniki klasyfikacji dla różnych parametrów wejściowych

Wstępne wyniki miary Accuracy dla próbnych klasyfikacji na ograniczonym zbiorze tekstów (podać parametry i kryteria wyboru wg punktów 3.-8. z opisu Projektu 1.). **Sekcja uzupełniona jako efekt zadania Tydzień 05 wg Harmonogramu Zajęć na WIKAMP KSR.**

6 Dyskusja, wnioski, sprawozdanie końcowe

We wnioskach z badania skomentować wyłącznie wpływ parametrów i cech na jakość procesu klasyfikacji. Innymi słowy – wnioski to to, co wynika z przeprowadzonych obliczeń, a nie to co wiadomo z literatury. Znaczenie kolejnych eksperymentów wg punktów 2.-8. opisu projektu 1. Każdorazowo podane parametry, dla których przeprowadzana eksperyment. Wykresy (np. słupkowe) i tabele wyników obowiązkowe, dokładnie opisane w „captions” (tytułach), konieczny opis osi i jednostek wykresów oraz kolumn i wierszy tabel.

Ewentualne wyniki realizacji punktu 9. opisu Projektu 1., czyli „na ocenę 5.0" i ich porównanie do wyników z części obowiązkowej.Dokładne interpretacje uzyskanych wyników w zależności od parametrów klasyfikacji opisanych w punktach 3.-8 opisu Projektu 1. Omówić i wyjaśnić napotkane problemy (jeśli były). Każdy wniosek/problem powinien mieć poparcie w przeprowadzonych eksperymentach (odwołania do konkretnych wyników: wykresów, tabel).
Dla końcowej oceny jest to najważniejsza sekcja sprawozdania, gdyż prezentuje poziom zrozumienia rozwiązywanego problemu.

** Możliwości kontynuacji prac w obszarze systemów rozpoznawania, zwłaszcza w kontekście pracy inżynierskiej, magisterskiej, naukowej, itp. **

Sekcja uzupełniona jako efekt zadań Tydzień 05 i Tydzień 06 wg Harmonogramu Zajęć na WIKAMP KSR.

7 Braki w realizacji projektu 1.

Wymienić wg opisu Projektu 1. wszystkie niezrealizowane obowiązkowe elementy projektu, ewentualnie podać merytoryczne (ale nie czasowe) przyczyny tych braków.

Literatura

[1] `http://archive.ics.uci.edu/dataset/137/reuters+21578+text+categorization+collection`

[2] Taunk, Kashvi; De, Sanjukta; Verma, Srishti; Swetapadma, Aleena. A Brief Review of Nearest Neighbor Algorithm for Learning and Classification. 2019, pp. 1255–1260. DOI: 10.1109/ICCS45141.2019.9065747.

[3] `https://www.mimuw.edu.pl/~wjaworski/SU/SU04_miary_jakosci.pdf`

Literatura zawiera wyłącznie źródła recenzowane i/lub o potwierdzonej wiarygodności, możliwe do weryfikacji i cytowane w sprawozdaniu.