Komputerowe systemy rozpoznawania
2024/2025
Projekt 1. Klasyfikacja dokumentów tekstowych

Mateusz Kosowski 251558
Nikodem Nowak 251598
dr inż. Marcin Kacprowicz

12 kwietnia 2026

Opis projektu ma formę artykułu naukowego lub raportu z zadania badawczego (doświadczalnego/obliczeniowego0 (wg indywidualnych potrzeb związanych np. z pracą inżynierską/naukową/zawodową). Kolejne sekcje muszą być numerowane i zatytułowane. Wzory są numerowane, tablice są numerowane i podpisane nad tablicą, rysunki są numerowane i podpisane pod rysunkiem. Podpis rysunku i tabeli musi być wyczerpujący (nie ogólnikowy), aby czytelnik nie musiał sięgać do tekstu, aby go zrozumieć.

Limit stron sprawozdania: 20. Nie zmieniać parametrów tekstu (czcionki, marginesów, interlinii, itp.). Istotne dla sprawozdania rysunki, tabele, informacje, kody itp. można umieścić w załącznikach, które nie wliczają się do limitu stron.

Wybrane sekcje (rozdziały sprawozdania) są uzupełniane wg wymagań w opisie Projektu 1. i Harmonogramie Zajęć na WIKAMP KSR jako efekty zadań w poszczególnych tygodniach.

1 Cel projektu

Badania będą prowadzone na gotowym zbiorze tekstów Reuters-21578 [1]. W celu przeprowadzenia obserwacji oraz wyciągnięcia wniosków zostanie napisana aplikacja. Jej zadaniem będzie ekstrakcja konkretnych cech tekstu, zamiana ich na wektory a następnie klasyfikacja w kategorii places, z możliwymi etykietami: west-germany, usa, france, uk, canada albo japan.

2 Klasyfikacja nadzorowana metodą k-NN. Ekstrakcja cech, wektory cech

2.1 Zasada działania metody k-NN

Algorytm k-NN (k najbliższych sąsiadów) [2] działa tak, że dla nowego, nieznanego dokumentu:

1. Szuka w bazie k tekstów najbardziej podobnych (najmniejsza odległość między wektorami cech).
2. Sprawdza, do jakich kategorii należą znalezieni sąsiedzi.
3. Przypisuje dokumentowi klasę najczęściej występującą wśród sąsiadów (głosowanie). W przypadku remisu stosuje odpowiednią metodę rozstrzygania.

2.2 Parametry wejściowe

- Wartość k (liczba sąsiadów).
- Proporcje podziału tekstów na zbiór uczący i testowy (np. 60/40).
- Wybrane cechy oraz metryka odległości (np. euklidesowa).

2.3 Wyniki i rezultaty

Program dla każdego tekstu testowego zwraca przewidywaną etykietę (np. `usa`). Na podstawie porównania tych przewidywań z rzeczywistymi kategoriami, program oblicza ostateczne wyniki w postaci czterech miar jakości:

- **Accuracy** (dokładność) – liczona dla całego zbioru dokumentów,
- **Precision** (precyzja) – liczona dla całego zbioru oraz oddzielnie dla każdej z 6 klas,
- **Recall** (czułość) – również dla całego zbioru i wybranych klas,
- **F1** – średnia harmoniczna miar Precision i Recall.

Dzięki tym parametrom można obiektywnie ocenić, jak dobrze model radzi sobie z przypisywaniem tekstów do odpowiednich państw.

2.4 Wyodrębnione cechy (wektory cech)

Dla każdego analizowanego dokumentu wyodrębniono wektor 10 cech (2 tekstowe i 8 liczbowych). Aby ułatwić zapis matematyczny, przyjęto następujące oznaczenia dla pojedynczego dokumentu:

- W – zbiór wszystkich słów w dokumencie, a $n = |W|$ to ich całkowita liczba,
- Z – zbiór wszystkich zdań w dokumencie, a $m = |Z|$ to ich całkowita liczba,
- C – zbiór wszystkich znaków w dokumencie, a $u = |C|$ to ich całkowita liczba,
- $|x|$ – operator oznaczający:
  - liczebność zbioru x, gdy x jest zbiorem,
  - długość elementu x, gdy x jest ciągiem (np. liczbę liter w słowie).

Poniżej przedstawiono definicje poszczególnych cech wektora:

1. **Najczęściej występujące słowo** (Most Frequent Word) – wartość tekstowa. Niech W' będzie zbiorem słów po usunięciu tzw. stop-words (spójników, przyimków). Funkcja szuka słowa w, które maksymalizuje liczbę swoich wystąpień $\text{count}(w)$:

$$c_1 = \max_{w \in W'} (\text{count}(w)) \tag{1}$$

   Przykład: `trade`.

2. **Najdłuższe słowo** (Longest Word) – wartość tekstowa. Słowo $w \in W$, dla którego liczba liter $|w|$ jest największa:

$$c_2 = \max_{w \in W} (|w|) \tag{2}$$

   Przykład: `internationalization`.

3. **Średnia długość słowa** (Average Word Length) – wartość liczbowa. Średnia długość słowa jest definiowana jako:

$$c_3 = \frac{1}{n} \sum_{i=1}^{n} |w_i| \tag{3}$$

   gdzie $|w_i|$ oznacza długość i-tego słowa wyrażoną liczbą znaków.
   Przykład: 5,43.

4. **Bogactwo słownictwa** (Vocabulary Richness) – wartość liczbowa. Stosunek liczby unikalnych słów do wszystkich słów w dokumencie. Niech $U \subseteq W$ będzie zbiorem słów unikalnych:

$$c_4 = \frac{|U|}{n} \tag{4}$$

   Przykład: 0,65.

5. **Średnia długość zdania** (Average Sentence Length) – wartość liczbowa. Średnia liczba słów przypadająca na jedno zdanie:

$$c_5 = \frac{n}{m} \tag{5}$$

Przykład: 15,2.

6. **Stosunek wielkich liter** (Uppercase Letter Ratio) – wartość liczbowa. Odsetek znaków, które są wielkimi literami. Jeśli C_{upper} to zbiór wielkich liter w tekście:

$$c_6 = \frac{|C_{\text{upper}}|}{u} \tag{6}$$

Przykład: 0,04.

7. **Zagęszczenie znaków finansowych** (Financial/Numerical Sign Density) – wartość liczbowa. Odsetek znaków specjalnych związanych z finansami (np. \$, %, £). Jeśli C_{fin} to zbiór takich znaków w tekście:

$$c_7 = \frac{|C_{\text{fin}}|}{u} \tag{7}$$

Przykład: 0,012.

8. **Indeks czytelności Flescha** (Flesch Reading Ease Index) – wartość liczbowa. Wzór oceniający trudność tekstu w jęz. angielskim, gdzie L_{sylab} to całkowita liczba sylab w tekście:

$$c_8 = 206{,}835 - 1{,}015 \cdot \left(\frac{n}{m}\right) - 84{,}6 \cdot \left(\frac{L_{\text{sylab}}}{n}\right) \tag{8}$$

Przykład: 60,5.

9. **Stosunek samogłosek do spółgłosek** (Vowel to Consonant Ratio) – wartość liczbowa. Niech V to liczba samogłosek, a C_{cons} to liczba spółgłosek:

$$c_9 = \frac{V}{C_{\text{cons}}} \tag{9}$$

Przykład: 0,73.

10. **Suma wartości liczbowych** (Sum of All Numerical Values) – wartość liczbowa. Suma matematyczna wszystkich liczb wyciągniętych z treści. Niech Num będzie zbiorem wszystkich wartości liczbowych:

$$c_{10} = \sum_{x \in Num} x \tag{10}$$

Przykład: 105,5.

2.5 Przykład wektora cech

Zgodnie z opisanymi wyżej wzorami, wyekstrahowany wektor v może przyjąć następującaci postać:

$$v = [\texttt{trade}, \texttt{internationalization}, 5.43, 0.65, 15.2, 0.04, 0.012, 60.5, 0.73, 105.5]$$

3 Miary jakości klasyfikacji

W procesie oceny jakości działania klasyfikatora k-NN wykorzystano cztery standardowe miary [3]. Pozwalają one na obiektywną ocenę zdolności modelu do poprawnego przypisywania etykiet dokumentom tekstowym.

Przyjęto następujące oznaczenia dla danej klasy k:

- TP_k (True Positives) – liczba dokumentów z klasy k, które zostały poprawnie zaklasyfikowane do klasy k,
- FP_k (False Positives) – liczba dokumentów spoza klasy k, które zostały błędnie zaklasyfikowane do klasy k,
- FN_k (False Negatives) – liczba dokumentów z klasy k, które zostały błędnie zaklasyfikowane do innej klasy,
- N – całkowita liczba dokumentów w zbiorze testowym.

3.1 Accuracy (Dokładność)

Accuracy określa ogólną skuteczność klasyfikatora jako stosunek liczby poprawnych decyzji do wszystkich podjętych decyzji:

$$Accuracy = \frac{\sum_k TP_k}{N} \tag{11}$$

Miara przyjmuje wartości z zakresu $[0, 1]$, gdzie 1 oznacza bezbłędną klasyfikację. Przykład: $Accuracy = 0{,}85$ (85% poprawnych trafień).

3.2 Precision (Precyzja)

Precyzja dla danej klasy k określa, jaka część dokumentów zaklasyfikowanych do tej klasy faktycznie do niej należy:

$$Precision_k = \frac{TP_k}{TP_k + FP_k} \tag{12}$$

Wysoka precyzja oznacza małą liczbę błędów typu False Positive. Przykład: $Precision_{\texttt{usa}} = 0{,}92$.

3.3 Recall (Pełność/Czułość)

Pełność dla danej klasy k określa, jaką część dokumentów z danej klasy udało się poprawnie wykryć:

$$Recall_k = \frac{TP_k}{TP_k + FN_k} \tag{13}$$

Wysoka pełność oznacza małą liczbę błędów typu False Negative. Przykład: $Recall_{\texttt{usa}} = 0{,}88$.

3.4 Miara F1

Miara F1 jest średnią harmoniczną precyzji i pełności. Pozwala na ocenę balansu między tymi dwiema miarami:

$$F1_k = 2 \cdot \frac{Precision_k \cdot Recall_k}{Precision_k + Recall_k} \tag{14}$$

Jest szczególnie użyteczna w przypadku zbiorów o nierównomiernym rozkładzie klas. Przykład: $F1_{\texttt{usa}} = 0{,}90$.

Dla całego zbioru (wyniki ogólne) stosowana jest średnia arytmetyczna miar cząstkowych dla wszystkich klas (tzw. średnia makro).

4 Metryki i miary podobieństwa tekstów w klasyfikacji

W implementacji klasyfikatora porównywane są pełne wektory cech

$$v^{(A)} = [c_1^{(A)}, c_2^{(A)}, \ldots, c_{10}^{(A)}], \qquad v^{(B)} = [c_1^{(B)}, c_2^{(B)}, \ldots, c_{10}^{(B)}], \tag{15}$$

gdzie zgodnie z oznaczeniami z sekcji 2 cechy c_1 i c_2 są tekstowe, natomiast $c_3, \ldots, c_{10}$ są liczbowe. W kodzie cechy liczbowe są najpierw normalizowane metodą min–max, a następnie do obliczenia odległości między wektorami stosowana jest jedna z trzech metryk wymaganych w projekcie: euklidesowa, uliczna lub Czebyszewa. Dla dwóch cech tekstowych wykorzystywana jest miara podobieństwa oparta na 2-gramach znakowych i współczynniku Sørensena-Dice'a [4, 5].

4.1 Normalizacja cech liczbowych

Dla każdej cechy liczbowej c_i, gdzie $i \in \{3, \ldots, 10\}$, przed klasyfikacją wyznaczana jest wartość znormalizowana:

$$\tilde{c}_i = \frac{c_i - c_i^{\min}}{c_i^{\max} - c_i^{\min}} \tag{16}$$

gdzie $c_i^{\min}$ i $c_i^{\max}$ oznaczają odpowiednio najmniejszą i największą wartość cechy c_i w zbiorze wektorów użytych do klasyfikacji. Jeśli dla danej cechy $c_i^{\max} = c_i^{\min}$, to implementacja przyjmuje $\tilde{c}_i = 0$.

Po takiej normalizacji każda cecha liczbowa przyjmuje wartości z przedziału $[0, 1]$. W dalszej części sekcji, dla uproszczenia zapisu, symbole $c_3, \ldots, c_{10}$ oznaczają już wartości po normalizacji. Dzięki temu żadna z cech liczbowych nie dominuje odległości tylko dlatego, że była wyrażona w większej skali liczbowej.

4.2 Miara podobieństwa dla cech tekstowych

Niech $G_2(s)$ oznacza zbiór wszystkich różnych 2-gramów (bigramów) napisu s. W implementacji dla dwóch tekstowych wartości cechy $s^{(A)}$ i $s^{(B)}$ obliczana jest najpierw miara podobieństwa Sørensena-Dice'a:

$$Sim_{SD}(s^{(A)}, s^{(B)}) = \frac{2 \cdot |G_2(s^{(A)}) \cap G_2(s^{(B)})|}{|G_2(s^{(A)})| + |G_2(s^{(B)})|} \tag{17}$$

Następnie podobieństwo to jest zamieniane na odległość:

$$d_{\text{text}}(s^{(A)}, s^{(B)}) = 1 - Sim_{SD}(s^{(A)}, s^{(B)}) \tag{18}$$

Miara Sim_{SD} przyjmuje wartości z przedziału $[0, 1]$. Wartość 1 oznacza identyczne zbiory 2-gramów, a wartość 0 oznacza brak wspólnych 2-gramów. Odpowiadająca jej odległość d_{text} również należy do przedziału $[0, 1]$, ale ma interpretację odwrotną: 0 oznacza pełną zgodność, a 1 maksymalną różnicę. W obecnej implementacji parametr n jest stały i równy 2, a dla napisów krótszych niż dwa znaki funkcja zwraca podobieństwo 0, a więc odległość równą 1.

Przykład dla pierwszej cechy tekstowej:

$$G_2(\texttt{trade}) = \{\texttt{tr}, \texttt{ra}, \texttt{ad}, \texttt{de}\} \tag{19}$$

$$G_2(\texttt{grade}) = \{\texttt{gr}, \texttt{ra}, \texttt{ad}, \texttt{de}\} \tag{20}$$

Wspólne 2-gramy to $\{\texttt{ra}, \texttt{ad}, \texttt{de}\}$, zatem:

$$Sim_{SD}(\texttt{trade}, \texttt{grade}) = \frac{2 \cdot 3}{4 + 4} = 0{,}75 \tag{21}$$

$$d_{\text{text}}(\texttt{trade}, \texttt{grade}) = 1 - 0{,}75 = 0{,}25 \tag{22}$$

4.3 Metryka euklidesowa

Niech

$$\delta_1 = d_{\text{text}}(c_1^{(A)}, c_1^{(B)}), \qquad \delta_2 = d_{\text{text}}(c_2^{(A)}, c_2^{(B)}) \tag{23}$$

oznaczają odległości dla dwóch cech tekstowych. Wtedy metryka euklidesowa przyjmuje postać:

$$d_E(v^{(A)}, v^{(B)}) = \sqrt{\delta_1^2 + \delta_2^2 + \sum_{i=3}^{10} \left(c_i^{(A)} - c_i^{(B)}\right)^2} \tag{24}$$

W bieżącej implementacji $d_E \in [0, \sqrt{10}]$, ponieważ każdy z dziesięciu składników wektora może różnić się co najwyżej o 1. Wartość 0 oznacza identyczne wektory cech, natomiast wartości bliższe $\sqrt{10} \approx 3{,}1623$ oznaczają bardzo duże różnice między dokumentami w wielu składowych jednocześnie. Metryka euklidesowa silniej akcentuje kilka większych rozbieżności niż wiele bardzo małych różnic.

4.4 Metryka uliczna (Manhattan)

Metryka uliczna jest sumą modułów różnic wszystkich składowych:

$$d_M(v^{(A)}, v^{(B)}) = \delta_1 + \delta_2 + \sum_{i=3}^{10} \left| c_i^{(A)} - c_i^{(B)} \right| \tag{25}$$

W bieżącej implementacji $d_M \in [0, 10]$. Wartość 0 oznacza pełną zgodność obu wektorów, a wartość bliska 10 oznacza, że większość cech różni się maksymalnie. Metryka uliczna traktuje wkład każdej cechy liniowo, dzięki czemu jest mniej wrażliwa na pojedyncze duże odchylenie niż metryka euklidesowa.

4.5 Metryka Czebyszewa

Metryka Czebyszewa bierze pod uwagę wyłącznie największą różnicę między odpowiadającymi sobie składowymi:

$$d_C(v^{(A)}, v^{(B)}) = \max \left\{ \delta_1, \delta_2, \left| c_3^{(A)} - c_3^{(B)} \right|, \ldots, \left| c_{10}^{(A)} - c_{10}^{(B)} \right| \right\} \tag{26}$$

W bieżącej implementacji $d_C \in [0, 1]$. Wartość 0 oznacza identyczne dokumenty, natomiast wartość bliska 1 oznacza, że istnieje przynajmniej jedna cecha, dla której dokumenty bardzo silnie się różnią. Metryka ta ignoruje sumaryczny efekt wielu małych różnic i koncentruje się na największym rozbieżnym wymiarze.

4.6 Przykład dla dwóch wektorów cech

Dla zilustrowania działania metryk rozważmy dwa przykładowe, już znormalizowane wektory:

$$v^{(A)} = [\texttt{trade}, \texttt{market}, 0{,}40, 0{,}65, 0{,}55, 0{,}10, 0{,}12, 0{,}70, 0{,}60, 0{,}30] \tag{27}$$

$$v^{(B)} = [\texttt{grade}, \texttt{marker}, 0{,}60, 0{,}50, 0{,}35, 0{,}08, 0{,}10, 0{,}65, 0{,}58, 0{,}40] \tag{28}$$

Dla pierwszej cechy tekstowej otrzymano już $\delta_1 = 0{,}25$. Dla drugiej cechy tekstowej mamy:

$$G_2(\texttt{market}) = \{\texttt{ma}, \texttt{ar}, \texttt{rk}, \texttt{ke}, \texttt{et}\} \tag{29}$$

$$G_2(\texttt{marker}) = \{\texttt{ma}, \texttt{ar}, \texttt{rk}, \texttt{ke}, \texttt{er}\} \tag{30}$$

$$Sim_{SD}(\texttt{market}, \texttt{marker}) = \frac{2 \cdot 4}{5 + 5} = 0{,}8 \tag{31}$$

$$\delta_2 = d_{\text{text}}(\texttt{market}, \texttt{marker}) = 1 - 0{,}8 = 0{,}2 \tag{32}$$

Pozostałe różnice bezwzględne dla cech liczbowych wynoszą odpowiednio: 0,20, 0,15, 0,20, 0,02, 0,02, 0,05, 0,02 oraz 0,10. Stąd:

$$d_E(v^{(A)}, v^{(B)}) = \sqrt{0{,}2187} \approx 0{,}468 \tag{33}$$

czyli po zsumowaniu kwadratów wszystkich różnic otrzymujemy wartość 0,2187 pod pierwiastkiem.

$$d_M(v^{(A)}, v^{(B)}) = 1{,}21 \tag{34}$$

$$d_C(v^{(A)}, v^{(B)}) = 0{,}25 \tag{35}$$

ponieważ największa pojedyncza różnica między składowymi obu wektorów wynosi właśnie 0,25.

Otrzymane wartości pokazują różne własności metryk. W tym przykładzie metryka euklidesowa i uliczna uwzględniają łączny efekt wszystkich rozbieżności, natomiast metryka Czebyszewa zwraca wyłącznie największą pojedynczą różnicę. Dla klasyfikatora k-NN oznacza to, że przy tym samym zbiorze cech różne metryki mogą prowadzić do innego uporządkowania sąsiadów, a w konsekwencji do innej decyzji klasyfikacyjnej.

5 Wyniki klasyfikacji dla różnych parametrów wejściowych

Eksperymenty przeprowadzono w trzech etapach sekwencyjnych (każdy kolejny etap korzysta z najlepszych ustawień poprzedniego), a następnie wyznaczono wynik finalny dla optymalnej konfiguracji. Pełne dane źródłowe dla wszystkich kombinacji parametrów znajdują się w plikach CSV dołączonych do projektu.

5.1 Etap 1 – dobór metryki odległości i wartości k

Warunki eksperymentu: podział zbioru 50/50 (uczący/testowy), wszystkie 10 cech, przeszukano $k \in \{1, \ldots, 30\}$ dla każdej z trzech metryk (Manhattan, euklidesowej, Czebyszewa). Wyniki agregowane jako wartości makro (średnia arytmetyczna po wszystkich 6 klasach). Kryterium wyboru najlepszej konfiguracji stanowiła miara S zdefiniowana jako średnia harmoniczna Accuracy i F1 makro:

$$S = \frac{2 \cdot Acc \cdot F1_{makro}}{Acc + F1_{makro}} \tag{36}$$

Miara S karze jednocześnie za niskie Accuracy (słabą ogólną skuteczność) i niskie F1 makro (słabe rozróżnianie klas mniejszościowych). Jest tożsama ze wzorem na F1 – stanowi zatem uogólnienie miary F1 na parę (Accuracy, F1 makro) zamiast (Precision, Recall).

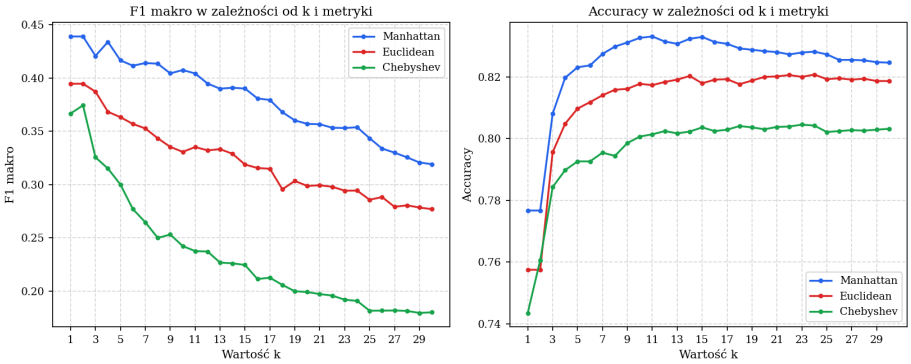

Rysunek 1: F1 makro (lewy panel) i Accuracy (prawy panel) w funkcji k dla trzech metryk odległości. Eksperyment przeprowadzony na podziale 50/50, z wykorzystaniem wszystkich 10 cech. Widoczna jest odwrotna zależność między F1 makro a Accuracy wraz ze wzrostem k – mimo rosnącej Accuracy ogólna zdolność rozróżniania klas maleje.

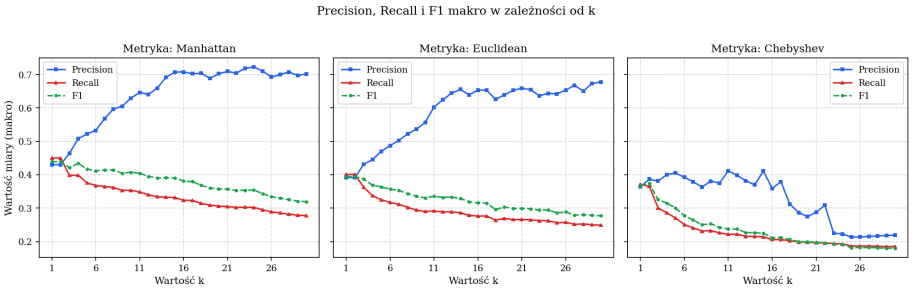

Rysunek 2: Precision makro, Recall makro i F1 makro w funkcji k dla każdej metryki oddzielnie. Wraz ze wzrostem k Precision rośnie, a Recall maleje – klasyfikator staje się coraz bardziej „ostrożny”: rzadziej przypisuje mniejszościowe klasy, więc gdy już to robi, częściej ma rację (wysoka precyzja), lecz pomija coraz więcej prawdziwych przykładów (niski recall). Optimum F1 dla metryki Manhattan leży przy $k = 4$.

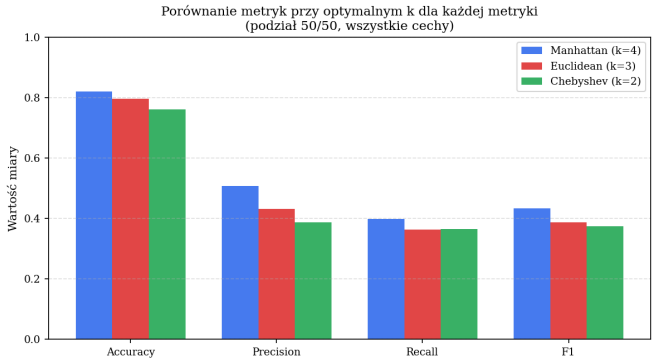

Rysunek 3: Porównanie miar Accuracy, Precision, Recall i F1 makro przy optymalnym k wyznaczonym niezależnie dla każdej metryki: Manhattan ($k = 4$), euklidesowej ($k = 3$), Czebyszewa ($k = 2$). Metryka Manhattan dominuje pod względem Recall i F1 makro, co oznacza lepszą równowagę między klasami.

Pełne wyniki dla wszystkich kombinacji metryki i k zebrano w tabeli 1. Przedstawiono wyłącznie konfiguracje o najwyższym wartości miary S dla każdej metryki.

Tabela 1: Najlepsze wyniki (wg miary S) dla każdej metryki w Etapie 1. Podział 50/50, wszystkie 10 cech.

Metryka	k	Accuracy	Precision	Recall	F1 makro	S
Manhattan	4	0,820	0,508	0,399	0,434	0,568
Euclidean	3	0,796	0,431	0,363	0,387	0,521
Chebyshev	2	0,761	0,387	0,365	0,374	0,502

Wybrana konfiguracja: metryka Manhattan, $k = 4$.

5.2 Etap 2 – dobór proporcji podziału zbioru

Warunki eksperymentu: metryka Manhattan, $k = 4$, wszystkie 10 cech. Sprawdzono dziewięć podziałów uczący/testowy: od 10/90 do 90/10 (co 10 pp.).

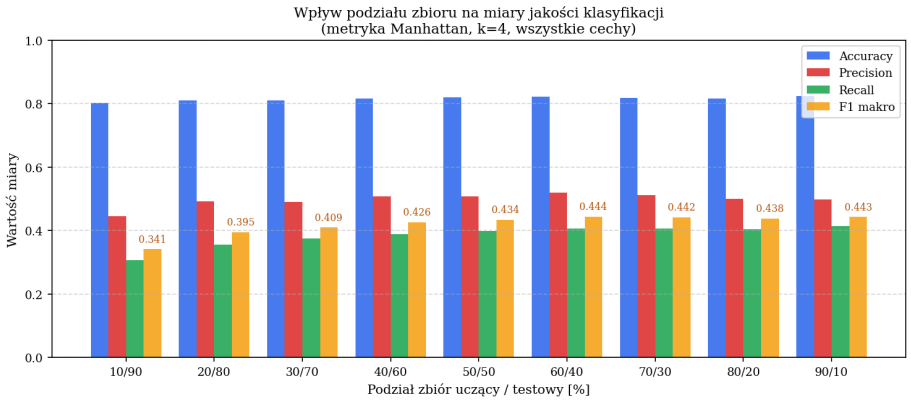

Rysunek 4: Wpływ proporcji podziału zbioru uczącego i testowego na Accuracy, Precision makro, Recall makro i F1 makro. Metryka Manhattan, $k = 4$, wszystkie 10 cech. Liczby nad słupkami F1 podają dokładne wartości. Recall rośnie wraz ze wzrostem zbioru uczącego, natomiast Accuracy i F1 osiągają maksimum przy podziale 60/40.

Tabela 2: Wyniki dla wszystkich proporcji podziału (Etap 2). Metryka Manhattan, $k = 4$, wszystkie 10 cech. Wartości makro.

Uczący	Testowy	Accuracy	Precision	Recall	F1 makro
10%	90%	0,802	0,446	0,307	0,341
20%	80%	0,811	0,491	0,355	0,395
30%	70%	0,811	0,491	0,376	0,409
40%	60%	0,816	0,508	0,389	0,426
50%	50%	0,820	0,508	0,399	0,434
60%	**40%**	**0,823**	**0,520**	**0,406**	**0,444**
70%	30%	0,819	0,512	0,407	0,442
80%	20%	0,816	0,499	0,405	0,438
90%	10%	0,825	0,498	0,413	0,443

Wybrana konfiguracja: podział 60%/40%.

5.3 Etap 3 – dobór podzbioru cech

Warunki eksperymentu: metryka Manhattan, $k = 4$, podział 60/40. Sprawdzono wszystkie $\binom{10}{1} + \binom{10}{2} + \cdots + \binom{10}{9} = 1\,013$ podzbiorów cech o liczności od 1 do 9 (pełny zestaw 10 cech był punktem odniesienia z Etapu 2).

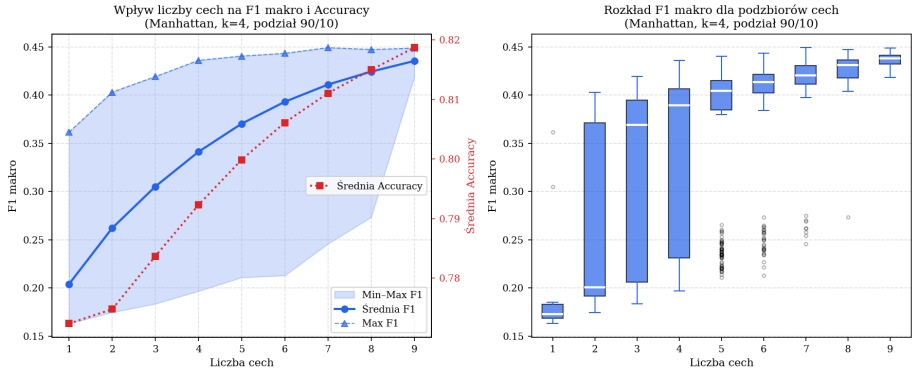

Rysunek 5: Lewy panel: średnia F1 makro (linia niebieska) i max F1 makro (linia przerywana) w funkcji liczby cech; zakres min–max zaznaczony wypełnieniem; oś prawa (czerwona) – średnia Accuracy. Prawy panel: rozkład F1 makro dla wszystkich podzbiorów danej liczności (wykres pudełkowy). Metryka Manhattan, $k = 4$, podział 60/40. Zarówno średnia, jak i maksymalna F1 rosną monotoniczne z liczbą cech, jednak wariancja wyników spada – mniejszy podzbiór jest silniej wrażliwy na dobór konkretnych cech.

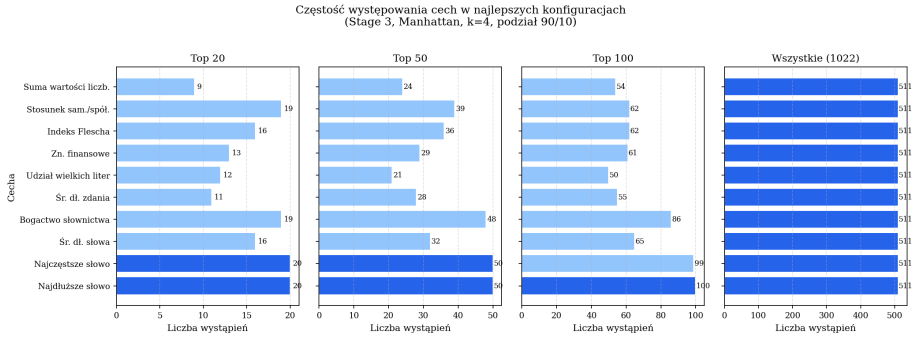

Rysunek 6: Częstość występowania każdej cechy w Top-20, Top-50, Top-100 i wszystkich 1 013 konfiguracjach (Etap 3, Manhattan, $k = 4$, podział 60/40). Cechy *Najdłuższe słowo* i *Najczęstsze słowo* dominują w każdym zakresie, co wskazuje na ich wysoką wartość dyskryminacyjną. *Indeks Flescha* i *Bogactwo słownictwa* zajmują kolejne miejsca w Top-20/50.

Tabela 3: Statystyki F1 makro i Accuracy według liczby cech (Etap 3). Metryka Manhattan, $k = 4$, podział 60/40. Kolumna n – liczba testowanych podzbiorów.

Liczba cech	n	Śr. F1	Max F1	Śr. Accuracy	Max Accuracy
1	10	0,204	0,362	0,772	0,815
2	45	0,262	0,403	0,775	0,812
3	120	0,305	0,419	0,784	0,813
4	210	0,341	0,436	0,792	0,819
5	252	0,370	0,441	0,800	0,820
6	210	0,393	0,443	0,806	0,822
7	120	0,411	0,449	0,811	0,822
8	45	0,424	0,447	0,815	0,823
9	**10**	0,435	**0,449**	0,819	**0,823**

Wybrana konfiguracja: 9 cech (wszystkie oprócz *sumOfAllNumericValues*): *longestWord* (najdłuższe słowo), *mostFrequentWord* (najczęstsze słowo), *averageWordLength* (śr. długość słowa), *vocabularyRichness* (bogactwo słownictwa), *averageSentenceLength* (śr. długość zdania), *uppercaseLetterRatio* (udział wielkich liter), *financialSignDensity* (znaki finansowe), *fleschReadingEaseIndex* (indeks czytelności Flescha), *vowelToConsonantRatio* (stosunek samogłosek do spółgłosek).

5.4 Wpływ poszczególnych cech na Accuracy

W celu wskazania, które cechy mają największy i najmniejszy wpływ na jakość klasyfikacji, przeprowadzono dwa uzupełniające eksperymenty (rysunek 7):

1. **Analiza jednej cechy:** klasyfikację uruchomiono osobno dla każdej z 10 cech (podzbiory 1-elementowe). Accuracy waha się od 0,760 (najczęstsze słowo) do 0,815 (najdłuższe słowo). Punkt odniesienia to Accuracy= 0,823 dla pełnego zestawu 10 cech.

2. **Ablacja (leave-one-out):** z pełnego zestawu 10 cech usuwano po jednej cesze i mierzono zmianę Accuracy względem baseline. Wyniki zebrano w tabeli 4.

Tabela 4: Wpływ usunięcia jednej cechy z pełnego zestawu 10 cech na Accuracy i F1 makro (ablacja). Baseline: Manhattan, $k = 4$, podział 60/40, 10 cech, Accuracy = 0,823, F1 = 0,444. Wartości Δ ujemne oznaczają, że usunięcie cechy *pogorszyło* wynik; wartości dodatnie – że cecha *nie wnosiła* użytecznej informacji.

Usunięta cecha	Accuracy	F1 makro	ΔAcc	ΔF1
Najdłuższe słowo	0,807	0,419	−0,016	−0,024
Najczęstsze słowo	0,812	0,419	−0,011	−0,025
Stosunek sam./spół.	0,818	0,431	−0,005	−0,012
Udział wielkich liter	0,820	0,442	−0,003	−0,002
Indeks Flescha	0,820	0,436	−0,003	−0,008
Zn. finansowe	0,820	0,441	−0,002	−0,003
Bogactwo słownictwa	0,822	0,435	−0,001	−0,009
Śr. długość zdania	0,822	0,442	±0,000	−0,002
Śr. długość słowa	0,823	0,441	+0,000	−0,003
Suma wartości liczb.	0,823	0,449	+0,000	+0,005

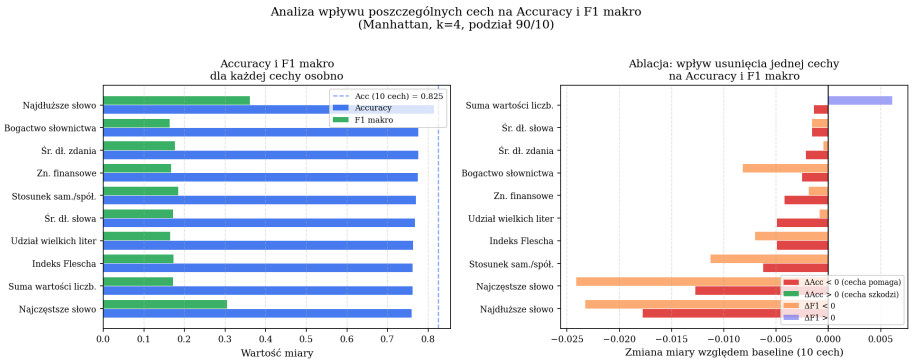

Rysunek 7: Lewy panel: Accuracy i F1 makro dla każdej cechy używanej osobno (podzbiory 1-elementowe); pionowa linia przerywana to Accuracy dla pełnego zestawu 10 cech. Prawy panel: zmiana Accuracy i F1 makro po usunięciu jednej cechy z zestawu 10 cech (ablacja); słupki czerwone oznaczają pogorszenie Accuracy, zielone – poprawę. Metryka Manhattan, $k = 4$, podział 60/40.

Z analizy ablacyjnej wynika, że **cechami o największym wpływie na Accuracy** są: *najdłuższe słowo* (ΔAcc = −0,016) i *najczęstsze słowo* (−0,011) – ich usunięcie powoduje największy spadek skuteczności. **Cechami o najmniejszym wpływie** są: *suma wartości liczbowych*, *śr. długość słowa* i *śr. długość zdania* (ΔAcc $\approx$ 0).

Interesującym przypadkiem jest *suma wartości liczbowych*: jej usunięcie praktycznie nie zmienia Accuracy (+0,000), ale poprawia F1 makro (+0,005). Oznacza to, że cecha ta wprowadza pewien szum przy klasyfikacji klas dominujących,

a jednocześnie nie pomaga klasom mniejszościowym – stąd właśnie jest jedyną cechą wykluczoną z optymalnego podzbioru 9 cech wyznaczonego w Etapie 3.

5.5 Wynik finalny – optymalna konfiguracja

Ostateczna klasyfikacja przeprowadzona z parametrami wyznaczonymi w Etapach 1–3 (metryka Manhattan, $k = 4$, podział 60/40, 9 cech) osiągnęła następujące wyniki makro: Accuracy = 0,823, Precision = 0,524, Recall = 0,412, F1 = 0,449. Wyniki dla poszczególnych klas zestawiono w tabeli 5 i na rysunku 8.

Tabela 5: Precision, Recall i F1 dla każdej z 6 klas oraz wartości makro – najlepsza konfiguracja (Manhattan, $k = 4$, podział 60/40, 9 cech).

Klasa	Precision	Recall	F1
usa	0,873	0,948	0,909
uk	0,615	0,508	0,556
japan	0,381	0,367	0,374
west-germany	0,453	0,264	0,333
france	0,414	0,224	0,291
canada	0,405	0,160	0,229
Makro	**0,524**	**0,412**	**0,449**
Accuracy			**0,823**

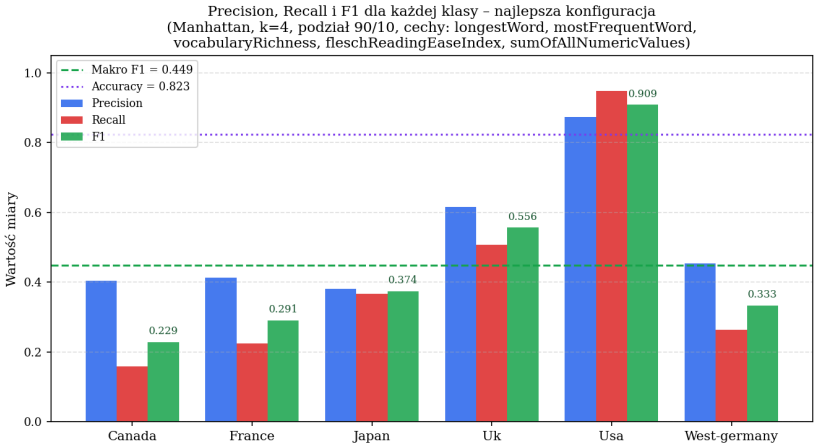

Rysunek 8: Precision, Recall i F1 dla każdej klasy – najlepsza konfiguracja (Manhattan, $k = 4$, podział 60/40, 9 cech: wszystkie oprócz *sumOfAllNumericValues*). Wartości F1 podane nad słupkami. Linie przerywane oznaczają wartości makro F1 i Accuracy dla całego zbioru testowego.

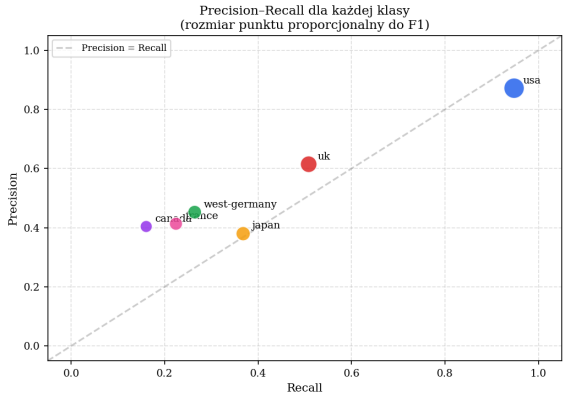

Rysunek 9: Diagram Precision–Recall dla każdej klasy. Rozmiar punktu jest proporcjonalny do wartości F1 danej klasy. Klasy o małej liczebności (canada, france) skupiają się w lewym dolnym rogu, co wskazuje na trudność z ich wykrywaniem. Klasa *usa* leży wyraźnie powyżej linii Precision = Recall, co oznacza, że model „preferuje" przypisywanie tej klasy (wysoki Recall kosztem nieco mniejszej Precision).

6 Dyskusja i wnioski

6.1 Wpływ metryki odległości

Spośród trzech badanych metryk najlepsze wyniki dała metryka Manhattan. Przy optymalnym dla niej $k = 4$ osiągnęła Accuracy = 0,820, F1 makro = 0,434 oraz $S = 0{,}568$. Metryka euklidesowa najlepszy wynik uzyskała przy $k = 3$ ($Accuracy = 0{,}796$, $F1 = 0{,}387$, $S = 0{,}521$), a metryka Czebyszewa przy $k = 2$ ($Accuracy = 0{,}761$, $F1 = 0{,}374$, $S = 0{,}502$). Co istotne, przewaga Manhattan nie ogranicza się do punktu optymalnego – jest widoczna konsekwentnie dla wszystkich badanych wartości k (rysunek 1).

Wynik ten można powiązać z charakterem porównywanych wektorów. Po normalizacji min–max różnice na poszczególnych cechach mieszczą się w przedziale $[0, 1]$ i zazwyczaj są niewielkie, ale rozkładają się na kilka wymiarów jednocześnie. Manhattan sumuje wszystkie te drobne różnice z równą wagą, dzięki czemu korzysta z informacji ze wszystkich cech naraz. Metryka euklidesowa, ze względu na podnoszenie różnic do kwadratu, mocniej akcentuje pojedyncze większe odchylenia kosztem wkładu pozostałych. Najsłabiej wypada metryka Czebyszewa, która z definicji bierze pod uwagę tylko jeden, największy wymiar – pozostałe dziewięć cech jest w niej całkowicie pomijanych przy każdej parze wektorów.

6.2 Wpływ wartości k

Na rysunkach 1 i 2 widać charakterystyczny „nożycowy” efekt: wraz ze wzrostem k Accuracy lekko rośnie (dla metryki Manhattan: od 0,777 przy $k = 1$ do 0,825 przy $k = 30$), natomiast F1 makro systematycznie spada (od 0,439 do 0,319). Jednocześnie Precision rośnie, a Recall maleje.

Wynika to wprost z niezbalansowania zbioru – klasa *usa* ma znacznie więcej dokumentów niż wszystkie pozostałe klasy razem. Przy małym k kilku sąsiadów z klasy mniejszościowej wystarcza, by przegłosować pojedynczych sąsiadów *usa*. Przy dużym k wśród branych pod uwagę sąsiadów zaczynają dominować dokumenty *usa*, więc klasyfikator coraz częściej odpowiada *usa* niezależnie od rzeczywistej klasy: liczba poprawnych trafień na klasie większościowej rośnie (Accuracy), ale klasy mniejszościowe są pomijane (Recall i F1 makro spadają). Najlepszy kompromis wypada przy $k = 4$ dla metryki Manhattan: F1 makro = 0,434 przy Accuracy = 0,820.

6.3 Wpływ podziału zbioru uczącego i testowego

Wyniki (tabela 2, rysunek 4) pokazują wyraźny wzrost jakości klasyfikacji wraz z powiększaniem zbioru uczącego: F1 makro rośnie z 0,341 przy podziale 10/90 do 0,444 przy 60/40, czyli o około 10 pp. Accuracy zmienia się znacznie mniej (z 0,802 do 0,825), bo wciąż jest zdominowana przez liczną klasę *usa* – nawet skromny zbiór uczący wystarcza, by ją dobrze rozpoznawać.

Najwyższą wartość kryterium S uzyskał podział 60/40 ($S = 0{,}577$). Powyżej tego progu (70/30, 80/20, 90/10) wyniki przestają się poprawiać, a F1 makro porusza się w wąskim pasie ok. 0,43–0,44. Sugeruje to, że klasyfikator przyswoił już praktycznie wszystko, co mógł nauczyć się z dostępnych danych, a powiększanie zbioru uczącego kosztem testowego nie przynosi już przyrostu jakości.

6.4 Wpływ wyboru cech

Z tabeli 3 wynika, że średnia F1 makro rośnie monotonicznie z liczbą używanych cech: od 0,204 dla pojedynczej cechy do 0,435 dla dziewięciu. Każda dodatkowa cecha wnosi więc średnio użyteczną informację. Najlepszy uzyskany wynik (F1 = 0,449, Acc = 0,823) odpowiada zestawowi 9 cech – pominięto wyłącznie *sumOfAllNumericValues*, której ablacja (tabela 4) pokazuje neutralny wpływ na Accuracy ($\Delta = +0{,}000$) i lekko dodatni na F1 ($\Delta = +0{,}005$). Dla tego konkretnego zbioru cecha ta zachowuje się więc raczej jak szum niż użyteczny sygnał.

Zwraca uwagę też kształt wykresu pudełkowego (rysunek 5): przy małej liczbie cech rozrzut F1 makro między różnymi podzbiorami jest bardzo szeroki i wynik silnie zależy od tego, które konkretnie cechy wybrano, natomiast przy 7–9 cechach poszczególne podzbiory mocno się ze sobą przekrywają i wybór staje się mniej krytyczny.

Zgodnie z analizą częstości na rysunku 6 cechy *longestWord* i *mostFrequentWord* pojawiają się praktycznie w każdej dobrej konfiguracji. Są to dwie cechy

tekstowe, porównywane miarą Sørensena-Dice'a. Ich wysoka wartość dyskryminacyjna potwierdza się w ablacji: ich usunięcie powoduje największe spadki Accuracy ($-0{,}016$ dla *longestWord* i $-0{,}011$ dla *mostFrequentWord*), wyraźnie większe niż dla którejkolwiek z cech liczbowych. Można to wytłumaczyć tym, że „najczęstsze" i „najdłuższe" słowo dokumentu często niesie informację tematyczną i geograficzną (nazwa firmy, miasta, instytucji), której pojedyncza statystyka liczbowa po prostu nie zawiera.

6.5 Wyniki dla poszczególnych klas

Tabela 5 i rysunek 8 ujawniają silną asymetrię wyników między klasami:

- **usa**: F1 = 0,909, Recall = 0,948. Klasyfikator wykrywa praktycznie wszystkie dokumenty tej klasy i jednocześnie utrzymuje wysoką Precision (0,873). Bezpośrednio wynika to z dominacji *usa* w zbiorze – klasa ta ma najwięcej sąsiadów w przestrzeni cech, więc nawet niewielkie podobieństwo wystarcza, by głosowanie wśród $k = 4$ sąsiadów wskazało *usa*.
- **uk**: F1 = 0,556, Precision = 0,615, Recall = 0,508. Nieco ponad połowa dokumentów z tej klasy jest poprawnie wykrywana, a około 62% przypisań do *uk* okazuje się trafnych. Pozostała część prawdziwych dokumentów UK trafia do innych klas, najczęściej *usa*.
- **japan**: F1 = 0,374, Precision i Recall na zbliżonym poziomie ($\approx 0{,}37$). Klasyfikator nie jest tu ani nadmiernie ostrożny, ani nadmiernie agresywny – po prostu w połowie przypadków nie znajduje wystarczającej liczby „japońskich" sąsiadów w sąsiedztwie testowanego dokumentu.
- **west-germany**, **france**, **canada**: F1 poniżej 0,34, Recall poniżej 0,27. Większość dokumentów z tych klas trafia do innej klasy, najczęściej *usa*. Przyczyną jest mała reprezentacja tych klas w zbiorze uczącym – przy $k = 4$ wystarczy, że wśród sąsiadów znajdą się dwa dokumenty *usa*, by głosowanie zignorowało prawdziwą etykietę.

Ogólna Accuracy = 0,823 na pierwszy rzut oka sugeruje dobry wynik, ale jest myląca: klasyfikator zawsze odpowiadający *usa* osiągnąłby tu podobnie wysoką wartość, a byłby praktycznie bezużyteczny. Właściwą miarą dla niezbalansowanych zbiorów jest F1 makro (= 0,449), liczona osobno dla każdej klasy i uśredniona.

6.6 Wnioski końcowe

1. Najlepsze wyniki uzyskała metryka Manhattan – konsekwentnie dla wszystkich wartości k, zarówno pod względem Accuracy, jak i F1 makro. Metryka Czebyszewa, wykorzystująca jedynie jeden wymiar wektora, wypadła najsłabiej.

2. Małe wartości k (rzędu kilku) zapewniają lepszy balans między Precision a Recall. Przy dużych k klasyfikator degeneruje się do klasyfikatora większościowego i pomija klasy mniejszościowe.

3. Powiększanie zbioru uczącego poprawia wyniki głównie dla klas mniejszościowych (Recall makro rośnie z 0,307 przy 10/90 do 0,406 przy 60/40). Powyżej podziału 60/40 dalszy wzrost zbioru uczącego nie przynosi już poprawy.

4. Optymalny zestaw 9 cech daje minimalnie lepszy wynik niż pełne 10 cech; jedyną wykluczoną cechą jest *sumOfAllNumericValues*. Cechy tekstowe (*longestWord*, *mostFrequentWord*) okazały się najbardziej dyskryminacyjne – ich usunięcie pogarsza wyniki najmocniej.

5. Niezbalansowanie klas w zbiorze Reuters-21578 silnie ogranicza jakość klasyfikacji klas mniejszościowych: *france* i *canada* mają F1 poniżej 0,30, mimo że globalna Accuracy przekracza 80%.

Literatura

[1] `http://archive.ics.uci.edu/dataset/137/reuters+21578+text+categorization+collection`

[2] Taunk, Kashvi; De, Sanjukta; Verma, Srishti; Swetapadma, Aleena.
A Brief Review of Nearest Neighbor Algorithm for Learning and Classification. 2019, pp. 1255–1260. DOI: 10.1109/ICCS45141.2019.9065747.
`https://www.researchgate.net/publication/340693569_A_Brief_Review_of_Nearest_Neighbor_Algorithm_for_Learning_and_Classification`

[3] Wojciech Jaworski
Miary jakości
`https://www.mimuw.edu.pl/~wjaworski/SU/SU04_miary_jakosci.pdf`

[4] Kondrak, Grzegorz.
N-Gram Similarity and Distance.
`https://webdocs.cs.ualberta.ca/~kondrak/papers/spire05.pdf`

[5] Avivit Levy, B. Riva Shalom, oraz Michal Chalamish.
A Guide to Similarity Measures.
`https://arxiv.org/pdf/2408.07706`

Literatura zawiera wyłącznie źródła recenzowane i/lub o potwierdzonej wiarygodności, możliwe do weryfikacji i cytowane w sprawozdaniu.