Komputerowe systemy rozpoznawania
2024/2025
Projekt 1. Klasyfikacja dokumentów tekstowych

Mateusz Kosowski 251558
Nikodem Nowak 251598
dr inż. Marcin Kacprowicz

29 marca 2026

Opis projektu ma formę artykułu naukowego lub raportu z zadania badawczego (doświadczalnego/obliczeniowego0 (wg indywidualnych potrzeb związanych np. z pracą inżynierską/naukową/zawodową). Kolejne sekcje muszą być numerowane i zatytułowane. Wzory są numerowane, tablice są numerowane i podpisane nad tablicą, rysunki są numerowane i podpisane pod rysunkiem. Podpis rysunku i tabeli musi być wyczerpujący (nie ogólnikowy), aby czytelnik nie musiał sięgać do tekstu, aby go zrozumieć.

Limit stron sprawozdania: 20. Nie zmieniać parametrów tekstu (czcionki, marginesów, interlinii, itp.). Istotne dla sprawozdania rysunki, tabele, informacje, kody itp. można umieścić w załącznikach, które nie wliczają się do limitu stron.

Wybrane sekcje (rozdziały sprawozdania) są uzupełniane wg wymagań w opisie Projektu 1. i Harmonogramie Zajęć na WIKAMP KSR jako efekty zadań w poszczególnych tygodniach.

1 Cel projektu

Badania będą prowadzone na gotowym zbiorze tekstów Reuters-21578 [1]. W celu przeprowadzenia obserwacji oraz wyciągnięcia wniosków zostanie napisana aplikacja. Jej zadaniem będzie ekstrakcja konkretnych cech tekstu, zamiana ich na wektory a następnie klasyfikacja w kategorii places, z możliwymi etykietami: west-germany, usa, france, uk, canada albo japan.

2 Klasyfikacja nadzorowana metodą k-NN. Ekstrakcja cech, wektory cech

2.1 Zasada działania metody k-NN

Algorytm k-NN (k najbliższych sąsiadów) [2] działa tak, że dla nowego, nieznanego dokumentu:

1. Szuka w bazie k tekstów najbardziej podobnych (najmniejsza odległość między wektorami cech).
2. Sprawdza, do jakich kategorii należą znalezieni sąsiedzi.
3. Przypisuje dokumentowi klasę najczęściej występującą wśród sąsiadów (głosowanie). W przypadku remisu stosuje odpowiednią metodę rozstrzygania.

2.2 Parametry wejściowe

- Wartość k (liczba sąsiadów).
- Proporcje podziału tekstów na zbiór uczący i testowy (np. 60/40).
- Wybrane cechy oraz metryka odległości (np. euklidesowa).

2.3 Wyniki i rezultaty

Program dla każdego tekstu testowego zwraca przewidywaną etykietę (np. `usa`). Na podstawie porównania tych przewidywań z rzeczywistymi kategoriami, program oblicza ostateczne wyniki w postaci czterech miar jakości:

- **Accuracy** (dokładność) – liczona dla całego zbioru dokumentów,
- **Precision** (precyzja) – liczona dla całego zbioru oraz oddzielnie dla każdej z 6 klas,
- **Recall** (czułość) – również dla całego zbioru i wybranych klas,
- **F1** – średnia harmoniczna miar Precision i Recall.

Dzięki tym parametrom można obiektywnie ocenić, jak dobrze model radzi sobie z przypisywaniem tekstów do odpowiednich państw.

2.4 Wyodrębnione cechy (wektory cech)

Dla każdego analizowanego dokumentu wyodrębniono wektor 10 cech (2 tekstowe i 8 liczbowych). Aby ułatwić zapis matematyczny, przyjęto następujące oznaczenia dla pojedynczego dokumentu:

- W – zbiór wszystkich słów w dokumencie, a $n = |W|$ to ich całkowita liczba,
- Z – zbiór wszystkich zdań w dokumencie, a $m = |Z|$ to ich całkowita liczba,
- C – zbiór wszystkich znaków w dokumencie, a $u = |C|$ to ich całkowita liczba,
- $|x|$ – operator oznaczający:
  - liczebność zbioru x, gdy x jest zbiorem,
  - długość elementu x, gdy x jest ciągiem (np. liczbę liter w słowie).

Poniżej przedstawiono definicje poszczególnych cech wektora:

1. **Najczęściej występujące słowo** (Most Frequent Word) – wartość tekstowa. Niech W' będzie zbiorem słów po usunięciu tzw. stop-words (spójników, przyimków). Funkcja szuka słowa w, które maksymalizuje liczbę swoich wystąpień $\text{count}(w)$:

$$c_1 = \max_{w \in W'} (\text{count}(w)) \tag{1}$$

   Przykład: `trade`.

2. **Najdłuższe słowo** (Longest Word) – wartość tekstowa. Słowo $w \in W$, dla którego liczba liter $|w|$ jest największa:

$$c_2 = \max_{w \in W} (|w|) \tag{2}$$

   Przykład: `internationalization`.

3. **Średnia długość słowa** (Average Word Length) – wartość liczbowa. Średnia długość słowa jest definiowana jako:

$$c_3 = \frac{1}{n} \sum_{i=1}^{n} |w_i| \tag{3}$$

   gdzie $|w_i|$ oznacza długość i-tego słowa wyrażoną liczbą znaków.
   Przykład: 5,43.

4. **Bogactwo słownictwa** (Vocabulary Richness) – wartość liczbowa. Stosunek liczby unikalnych słów do wszystkich słów w dokumencie. Niech $U \subseteq W$ będzie zbiorem słów unikalnych:

$$c_4 = \frac{|U|}{n} \tag{4}$$

   Przykład: 0,65.

5. **Średnia długość zdania** (Average Sentence Length) – wartość liczbowa. Średnia liczba słów przypadająca na jedno zdanie:

$$c_5 = \frac{n}{m} \tag{5}$$

Przykład: 15,2.

6. **Stosunek wielkich liter** (Uppercase Letter Ratio) – wartość liczbowa. Odsetek znaków, które są wielkimi literami. Jeśli C_{upper} to zbiór wielkich liter w tekście:

$$c_6 = \frac{|C_{\text{upper}}|}{u} \tag{6}$$

Przykład: 0,04.

7. **Zagęszczenie znaków finansowych** (Financial/Numerical Sign Density) – wartość liczbowa. Odsetek znaków specjalnych związanych z finansami (np. \$, %, £). Jeśli C_{fin} to zbiór takich znaków w tekście:

$$c_7 = \frac{|C_{\text{fin}}|}{u} \tag{7}$$

Przykład: 0,012.

8. **Indeks czytelności Flescha** (Flesch Reading Ease Index) – wartość liczbowa. Wzór oceniający trudność tekstu w jęz. angielskim, gdzie L_{sylab} to całkowita liczba sylab w tekście:

$$c_8 = 206{,}835 - 1{,}015 \cdot \left(\frac{n}{m}\right) - 84{,}6 \cdot \left(\frac{L_{\text{sylab}}}{n}\right) \tag{8}$$

Przykład: 60,5.

9. **Stosunek samogłosek do spółgłosek** (Vowel to Consonant Ratio) – wartość liczbowa. Niech V to liczba samogłosek, a C_{cons} to liczba spółgłosek:

$$c_9 = \frac{V}{C_{\text{cons}}} \tag{9}$$

Przykład: 0,73.

10. **Suma wartości liczbowych** (Sum of All Numerical Values) – wartość liczbowa. Suma matematyczna wszystkich liczb wyciągniętych z treści. Niech Num będzie zbiorem wszystkich wartości liczbowych:

$$c_{10} = \sum_{x \in Num} x \tag{10}$$

Przykład: 105,5.

2.5 Przykład wektora cech

Zgodnie z opisanymi wyżej wzorami, wyekstrahowany wektor v może przyjąć następującaci postać:

$$v = [\texttt{trade}, \texttt{internationalization}, 5.43, 0.65, 15.2, 0.04, 0.012, 60.5, 0.73, 105.5]$$

3 Miary jakości klasyfikacji

W procesie oceny jakości działania klasyfikatora k-NN wykorzystano cztery standardowe miary [3]. Pozwalają one na obiektywną ocenę zdolności modelu do poprawnego przypisywania etykiet dokumentom tekstowym.

Przyjęto następujące oznaczenia dla danej klasy k:

- TP_k (True Positives) – liczba dokumentów z klasy k, które zostały poprawnie zaklasyfikowane do klasy k,
- FP_k (False Positives) – liczba dokumentów spoza klasy k, które zostały błędnie zaklasyfikowane do klasy k,
- FN_k (False Negatives) – liczba dokumentów z klasy k, które zostały błędnie zaklasyfikowane do innej klasy,
- N – całkowita liczba dokumentów w zbiorze testowym.

3.1 Accuracy (Dokładność)

Accuracy określa ogólną skuteczność klasyfikatora jako stosunek liczby poprawnych decyzji do wszystkich podjętych decyzji:

$$Accuracy = \frac{\sum_k TP_k}{N} \tag{11}$$

Miara przyjmuje wartości z zakresu $[0, 1]$, gdzie 1 oznacza bezbłędną klasyfikację. Przykład: $Accuracy = 0{,}85$ (85% poprawnych trafień).

3.2 Precision (Precyzja)

Precyzja dla danej klasy k określa, jaka część dokumentów zaklasyfikowanych do tej klasy faktycznie do niej należy:

$$Precision_k = \frac{TP_k}{TP_k + FP_k} \tag{12}$$

Wysoka precyzja oznacza małą liczbę błędów typu False Positive. Przykład: $Precision_{\texttt{usa}} = 0{,}92$.

3.3 Recall (Pełność/Czułość)

Pełność dla danej klasy k określa, jaką część dokumentów z danej klasy udało się poprawnie wykryć:

$$Recall_k = \frac{TP_k}{TP_k + FN_k} \tag{13}$$

Wysoka pełność oznacza małą liczbę błędów typu False Negative. Przykład: $Recall_{\texttt{usa}} = 0{,}88$.

3.4 Miara F1

Miara F1 jest średnią harmoniczną precyzji i pełności. Pozwala na ocenę balansu między tymi dwiema miarami:

$$F1_k = 2 \cdot \frac{Precision_k \cdot Recall_k}{Precision_k + Recall_k} \tag{14}$$

Jest szczególnie użyteczna w przypadku zbiorów o nierównomiernym rozkładzie klas. Przykład: $F1_{\texttt{usa}} = 0{,}90$.

Dla całego zbioru (wyniki ogólne) stosowana jest średnia arytmetyczna miar cząstkowych dla wszystkich klas (tzw. średnia makro).

4 Metryki i miary podobieństwa tekstów w klasyfikacji

W implementacji klasyfikatora porównywane są pełne wektory cech

$$v^{(A)} = [c_1^{(A)}, c_2^{(A)}, \ldots, c_{10}^{(A)}], \qquad v^{(B)} = [c_1^{(B)}, c_2^{(B)}, \ldots, c_{10}^{(B)}], \tag{15}$$

gdzie zgodnie z oznaczeniami z sekcji 2 cechy c_1 i c_2 są tekstowe, natomiast $c_3, \ldots, c_{10}$ są liczbowe. W kodzie cechy liczbowe są najpierw normalizowane metodą min–max, a następnie do obliczenia odległości między wektorami stosowana jest jedna z trzech metryk wymaganych w projekcie: euklidesowa, uliczna lub Czebyszewa. Dla dwóch cech tekstowych wykorzystywana jest miara podobieństwa oparta na 2-gramach znakowych i współczynniku Sørensena-Dice'a [4, 5].

4.1 Normalizacja cech liczbowych

Dla każdej cechy liczbowej c_i, gdzie $i \in \{3, \ldots, 10\}$, przed klasyfikacją wyznaczana jest wartość znormalizowana:

$$\tilde{c}_i = \frac{c_i - c_i^{\min}}{c_i^{\max} - c_i^{\min}} \tag{16}$$

gdzie $c_i^{\min}$ i $c_i^{\max}$ oznaczają odpowiednio najmniejszą i największą wartość cechy c_i w zbiorze wektorów użytych do klasyfikacji. Jeśli dla danej cechy $c_i^{\max} = c_i^{\min}$, to implementacja przyjmuje $\tilde{c}_i = 0$.

Po takiej normalizacji każda cecha liczbowa przyjmuje wartości z przedziału $[0, 1]$. W dalszej części sekcji, dla uproszczenia zapisu, symbole $c_3, \ldots, c_{10}$ oznaczają już wartości po normalizacji. Dzięki temu żadna z cech liczbowych nie dominuje odległości tylko dlatego, że była wyrażona w większej skali liczbowej.

4.2 Miara podobieństwa dla cech tekstowych

Niech $G_2(s)$ oznacza zbiór wszystkich różnych 2-gramów (bigramów) napisu s. W implementacji dla dwóch tekstowych wartości cechy $s^{(A)}$ i $s^{(B)}$ obliczana jest najpierw miara podobieństwa Sørensena-Dice'a:

$$Sim_{SD}(s^{(A)}, s^{(B)}) = \frac{2 \cdot |G_2(s^{(A)}) \cap G_2(s^{(B)})|}{|G_2(s^{(A)})| + |G_2(s^{(B)})|} \tag{17}$$

Następnie podobieństwo to jest zamieniane na odległość:

$$d_{\text{text}}(s^{(A)}, s^{(B)}) = 1 - Sim_{SD}(s^{(A)}, s^{(B)}) \tag{18}$$

Miara Sim_{SD} przyjmuje wartości z przedziału $[0, 1]$. Wartość 1 oznacza identyczne zbiory 2-gramów, a wartość 0 oznacza brak wspólnych 2-gramów. Odpowiadająca jej odległość d_{text} również należy do przedziału $[0, 1]$, ale ma interpretację odwrotną: 0 oznacza pełną zgodność, a 1 maksymalną różnicę. W obecnej implementacji parametr n jest stały i równy 2, a dla napisów krótszych niż dwa znaki funkcja zwraca podobieństwo 0, a więc odległość równą 1.

Przykład dla pierwszej cechy tekstowej:

$$G_2(\texttt{trade}) = \{\texttt{tr}, \texttt{ra}, \texttt{ad}, \texttt{de}\} \tag{19}$$

$$G_2(\texttt{grade}) = \{\texttt{gr}, \texttt{ra}, \texttt{ad}, \texttt{de}\} \tag{20}$$

Wspólne 2-gramy to $\{\texttt{ra}, \texttt{ad}, \texttt{de}\}$, zatem:

$$Sim_{SD}(\texttt{trade}, \texttt{grade}) = \frac{2 \cdot 3}{4 + 4} = 0{,}75 \tag{21}$$

$$d_{\text{text}}(\texttt{trade}, \texttt{grade}) = 1 - 0{,}75 = 0{,}25 \tag{22}$$

4.3 Metryka euklidesowa

Niech

$$\delta_1 = d_{\text{text}}(c_1^{(A)}, c_1^{(B)}), \qquad \delta_2 = d_{\text{text}}(c_2^{(A)}, c_2^{(B)}) \tag{23}$$

oznaczają odległości dla dwóch cech tekstowych. Wtedy metryka euklidesowa przyjmuje postać:

$$d_E(v^{(A)}, v^{(B)}) = \sqrt{\delta_1^2 + \delta_2^2 + \sum_{i=3}^{10} \left(c_i^{(A)} - c_i^{(B)}\right)^2} \tag{24}$$

W bieżącej implementacji $d_E \in [0, \sqrt{10}]$, ponieważ każdy z dziesięciu składników wektora może różnić się co najwyżej o 1. Wartość 0 oznacza identyczne wektory cech, natomiast wartości bliższe $\sqrt{10} \approx 3{,}1623$ oznaczają bardzo duże różnice między dokumentami w wielu składowych jednocześnie. Metryka euklidesowa silniej akcentuje kilka większych rozbieżności niż wiele bardzo małych różnic.

4.4 Metryka uliczna (Manhattan)

Metryka uliczna jest sumą modułów różnic wszystkich składowych:

$$d_M(v^{(A)}, v^{(B)}) = \delta_1 + \delta_2 + \sum_{i=3}^{10} \left| c_i^{(A)} - c_i^{(B)} \right| \tag{25}$$

W bieżącej implementacji $d_M \in [0, 10]$. Wartość 0 oznacza pełną zgodność obu wektorów, a wartość bliska 10 oznacza, że większość cech różni się maksymalnie. Metryka uliczna traktuje wkład każdej cechy liniowo, dzięki czemu jest mniej wrażliwa na pojedyncze duże odchylenie niż metryka euklidesowa.

4.5 Metryka Czebyszewa

Metryka Czebyszewa bierze pod uwagę wyłącznie największą różnicę między odpowiadającymi sobie składowymi:

$$d_C(v^{(A)}, v^{(B)}) = \max \left\{ \delta_1, \delta_2, \left| c_3^{(A)} - c_3^{(B)} \right|, \ldots, \left| c_{10}^{(A)} - c_{10}^{(B)} \right| \right\} \tag{26}$$

W bieżącej implementacji $d_C \in [0, 1]$. Wartość 0 oznacza identyczne dokumenty, natomiast wartość bliska 1 oznacza, że istnieje przynajmniej jedna cecha, dla której dokumenty bardzo silnie się różnią. Metryka ta ignoruje sumaryczny efekt wielu małych różnic i koncentruje się na największym rozbieżnym wymiarze.

4.6 Przykład dla dwóch wektorów cech

Dla zilustrowania działania metryk rozważmy dwa przykładowe, już znormalizowane wektory:

$$v^{(A)} = [\texttt{trade}, \texttt{market}, 0{,}40, 0{,}65, 0{,}55, 0{,}10, 0{,}12, 0{,}70, 0{,}60, 0{,}30] \tag{27}$$

$$v^{(B)} = [\texttt{grade}, \texttt{marker}, 0{,}60, 0{,}50, 0{,}35, 0{,}08, 0{,}10, 0{,}65, 0{,}58, 0{,}40] \tag{28}$$

Dla pierwszej cechy tekstowej otrzymano już $\delta_1 = 0{,}25$. Dla drugiej cechy tekstowej mamy:

$$G_2(\texttt{market}) = \{\texttt{ma}, \texttt{ar}, \texttt{rk}, \texttt{ke}, \texttt{et}\} \tag{29}$$

$$G_2(\texttt{marker}) = \{\texttt{ma}, \texttt{ar}, \texttt{rk}, \texttt{ke}, \texttt{er}\} \tag{30}$$

$$Sim_{SD}(\texttt{market}, \texttt{marker}) = \frac{2 \cdot 4}{5 + 5} = 0{,}8 \tag{31}$$

$$\delta_2 = d_{\mathrm{text}}(\texttt{market}, \texttt{marker}) = 1 - 0{,}8 = 0{,}2 \tag{32}$$

Pozostałe różnice bezwzględne dla cech liczbowych wynoszą odpowiednio: 0,20, 0,15, 0,20, 0,02, 0,02, 0,05, 0,02 oraz 0,10. Stąd:

$$d_E(v^{(A)}, v^{(B)}) = \sqrt{0{,}2187} \approx 0{,}468 \tag{33}$$

czyli po zsumowaniu kwadratów wszystkich różnic otrzymujemy wartość 0,2187 pod pierwiastkiem.

$$d_M(v^{(A)}, v^{(B)}) = 1{,}21 \tag{34}$$

$$d_C(v^{(A)}, v^{(B)}) = 0{,}25 \tag{35}$$

ponieważ największa pojedyncza różnica między składowymi obu wektorów wynosi właśnie 0,25.

Otrzymane wartości pokazują różne własności metryk. W tym przykładzie metryka euklidesowa i uliczna uwzględniają łączny efekt wszystkich rozbieżności, natomiast metryka Czebyszewa zwraca wyłącznie największą pojedynczą różnicę. Dla klasyfikatora k-NN oznacza to, że przy tym samym zbiorze cech różne metryki mogą prowadzić do innego uporządkowania sąsiadów, a w konsekwencji do innej decyzji klasyfikacyjnej.

5 Wyniki klasyfikacji dla różnych parametrów wejściowych

Wstępne wyniki miary Accuracy dla próbnych klasyfikacji na ograniczonym zbiorze tekstów (podać parametry i kryteria wyboru wg punktów 3.-8. z opisu Projektu 1.). **Sekcja uzupełniona jako efekt zadania Tydzień 05 wg Harmonogramu Zajęć na WIKAMP KSR.**

6 Dyskusja, wnioski, sprawozdanie końcowe

We wnioskach z badania skomentować wyłącznie wpływ parametrów i cech na jakość procesu klasyfikacji. Innymi słowy – wnioski to to, co wynika z przeprowadzonych obliczeń, a nie to co wiadomo z literatury. Znaczenie kolejnych eksperymentów wg punktów 2.-8. opisu projektu 1. Każdorazowo podane parametry, dla których przeprowadzana eksperyment. Wykresy (np. słupkowe) i tabele wyników obowiązkowe, dokładnie opisane w „captions" (tytułach), konieczny opis osi i jednostek wykresów oraz kolumn i wierszy tabel.

Ewentualne wyniki realizacji punktu 9. opisu Projektu 1., czyli „na ocenę 5.0", i ich porównanie do wyników z części obowiązkowej. Dokładne interpretacje uzyskanych wyników w zależności od parametrów klasyfikacji opisanych w punktach 3.-8 opisu Projektu 1. Omówić i wyjaśnić napotkane problemy (jeśli były). Każdy wniosek/problem powinien mieć poparcie w przeprowadzonych eksperymentach (odwołania do konkretnych wyników: wykresów, tabel).
Dla końcowej oceny jest to najważniejsza sekcja sprawozdania, gdyż prezentuje

poziom zrozumienia rozwiązywanego problemu.

Możliwości kontynuacji prac w obszarze systemów rozpoznawania, zwłaszcza w kontekście pracy inżynierskiej, magisterskiej, naukowej, itp.

Sekcja uzupełniona jako efekt zadań Tydzień 05 i Tydzień 06 wg Harmonogramu Zajęć na WIKAMP KSR.

7 Braki w realizacji projektu 1.

Wymienić wg opisu Projektu 1. wszystkie niezrealizowane obowiązkowe elementy projektu, ewentualnie podać merytoryczne (ale nie czasowe) przyczyny tych braków.

Literatura

[1] `http://archive.ics.uci.edu/dataset/137/reuters+21578+text+categorization+collection`

[2] Taunk, Kashvi; De, Sanjukta; Verma, Srishti; Swetapadma, Aleena. A Brief Review of Nearest Neighbor Algorithm for Learning and Classification. 2019, pp. 1255–1260. DOI: 10.1109/ICCS45141.2019.9065747.

[3] `https://www.mimuw.edu.pl/~wjaworski/SU/SU04_miary_jakosci.pdf`

[4] Kondrak, Grzegorz. N-Gram Similarity and Distance. `https://webdocs.cs.ualberta.ca/~kondrak/papers/spire05.pdf`

[5] Avivit Levy, B. Riva Shalom, oraz Michal Chalamish. A Guide to Similarity Measures. `https://arxiv.org/pdf/2408.07706`

Literatura zawiera wyłącznie źródła recenzowane i/lub o potwierdzonej wiarygodności, możliwe do weryfikacji i cytowane w sprawozdaniu.